

Análisis de la Relación entre las Energías Renovables y las Emisiones de CO₂ en Colombia (1990–2021)

Proyecto Final – Ciencia de Datos

Integrantes

Juan Castillo
Maira Martínez
Jorge Bernal
Samuel Solano

Docente: Camila Silva Gómez

Universidad EAN

Bogotá, Colombia

12 de septiembre de 2026

1 Descripción del Proyecto

Este repositorio contiene el desarrollo completo del proyecto final del curso de Ciencia de Datos, cuyo objetivo es analizar la evolución de las emisiones de dióxido de carbono (CO₂) en Colombia entre 1990 y 2021, en relación con el crecimiento de la generación de energía eléctrica a partir de fuentes renovables.

Pregunta de investigación

¿Qué relación existe entre el crecimiento de las energías renovables y las emisiones de CO₂ en Colombia entre 1990 y 2021?

Objetivo

Determinar el tipo y la magnitud de la relación entre la participación de energías renovables en la matriz eléctrica y las emisiones de CO₂ per cápita en Colombia, a partir de un análisis estadístico y de modelos de aprendizaje automático (*machine learning*) aplicados a series de tiempo del periodo 1990–2021.

2 Fuente de los Datos

La información utilizada proviene de dos conjuntos de datos públicos publicados por **Our World in Data (OWID)**, alojados en su repositorio oficial de GitHub:

- **CO2 and Greenhouse Gas Emissions Dataset:** <https://github.com/owid/co2-data>
- **Energy Dataset:** <https://github.com/owid/energy-data>

Se seleccionaron estas fuentes por tratarse de bases de datos abiertas, actualizadas periódicamente y ampliamente utilizadas en investigación académica sobre energía y cambio climático, lo que garantiza trazabilidad y confiabilidad de la información.

De ambos conjuntos se extrajeron únicamente los registros correspondientes a **Colombia** en el rango de años **1990–2021**.

3 Descripción de las Variables

Tras el proceso de limpieza, la tabla analítica final (`df_clean`) quedó conformada por las siguientes variables:

Variable	Descripción
Year	Año de observación (1990–2021).
C02_Mt	Emisiones totales de CO ₂ de Colombia, en millones de toneladas (Mt).
C02_per_capita	Emisiones de CO ₂ por habitante, en toneladas por persona.
Renewables_pct	Porcentaje de electricidad generada a partir de fuentes renovables.
Energy_per_capita	Consumo de energía primaria por habitante.
population	Población total de Colombia para el año correspondiente.

4 Proceso de Limpieza y Preprocesamiento de Datos

El tratamiento de los datos se realizó en Python (pandas) siguiendo los pasos que se describen a continuación:

1. **Carga de datos:** lectura directa de los archivos `owid-co2-data.csv` y `owid-energy-data.csv` desde el repositorio oficial de OWID en GitHub.
2. **Filtrado:** de cada dataset se conservaron únicamente los registros donde `country == Colombia` y el año estuviera entre 1990 y 2021.
3. **Selección y renombrado de columnas:** se conservaron las variables relevantes de cada fuente:
 - Del dataset de CO₂: `year`, `co2` (renombrada a `C02_Mt`) y `population`.
 - Del dataset de energía: `year`, `renewables_share_elec` (renombrada a `Renewables_pct`) y `primary_energy_consumption` (renombrada a `Energy_TWh`).
4. **Unión de tablas:** los dos subconjuntos se combinaron mediante un *merge* por la columna `year`, generando una única tabla (`df_colombia`) con todas las variables alineadas por año.
5. **Cálculo de variables per cápita:** a partir de las variables absolutas y la población, se calcularon `C02_per_capita` y `Energy_per_capita`, para permitir comparaciones normalizadas por habitante.
6. **Estandarización de nombres:** la columna `year` se renombró a `Year` para mantener consistencia en el resto del análisis.
7. **Consolidación final:** se construyó la tabla analítica `df_clean`, con las seis variables finales listas para el análisis exploratorio, estadístico y de modelado.
8. **Exportación:** la base limpia se exportó a un archivo Excel (`datos_limpios_colombia_1990_2021.xlsx`) para su respaldo y consulta.

No se identificaron valores nulos ni duplicados en el rango seleccionado, dado que ambos datasets de OWID cuentan con series completas para Colombia en el periodo de estudio.

Fragmento de código: filtrado, unión y cálculo per cápita

```

1  # Filtrado por país y periodo (1990-2021)
2  col_co2 = df_co2_raw[(df_co2_raw['country'] == 'Colombia') &
3                      (df_co2_raw['year'].between(1990, 2021))].copy()
4
5  # Selección y renombrado de columnas relevantes
6  col_co2 = col_co2[['year', 'co2', 'population']].rename(
7      columns={'co2': 'CO2_Mt'})
8  col_energy = col_energy[['year', 'renewables_share_elec',
9                          'primary_energy_consumption']].rename(
10     columns={'renewables_share_elec': 'Renewables_pct',
11             'primary_energy_consumption': 'Energy_TWh'})
12
13 # Unión de las dos fuentes de datos por año
14 df_colombia = pd.merge(col_co2, col_energy, on='year')
15
16 # Cálculo de variables per cápita
17 df_colombia['CO2_per_capita'] = (df_colombia['CO2_Mt'] * 1e6) / df_colombia['
18     population']
19 df_colombia['Energy_per_capita'] = (df_colombia['Energy_TWh'] * 1e9) / df_colombia[
20     'population']

```

5 Resultados Principales

Tendencias generales (1990–2021)

Las emisiones de CO₂ en Colombia pasaron de 56.9 Mt en 1990 a 103.7 Mt en 2021, mientras que la participación de electricidad renovable se mantuvo relativamente estable, pasando de 72.6 % a 75.1 % en el mismo periodo.

Correlaciones (variables per cápita)

- Electricidad renovable (%) vs. CO₂ per cápita: $r = -0,601$ (relación negativa moderada).
- Energía per cápita vs. CO₂ per cápita: $r = 0,690$ (relación positiva moderada-alta).

Comparación de modelos (validación Leave-One-Out, n=32)

Modelo	R ²	RMSE	MAE
KNN (k=6)	0.728	0.107	0.076
Ridge (L2)	0.692	0.114	0.093
Regresión Lineal	0.692	0.114	0.093
Lasso (L1)	0.688	0.115	0.094
Random Forest	0.574	0.134	0.090
Árbol de Decisión	0.419	0.156	0.114

El modelo con mejor desempeño fue **KNN (k=6)**, con un R² de 0.728 bajo validación Leave-One-Out, seguido de cerca por Ridge y la Regresión Lineal. Los modelos basados en árboles (Random

Forest y Árbol de Decisión) tuvieron el desempeño más bajo, probablemente por el tamaño reducido de la muestra (n=32 años).

6 Estructura del Repositorio

README.tex / README.pdf	Este documento
Informe_Final.pdf	Informe completo del proyecto
Presentacion.pdf	Diapositivas de la sustentación
Notebook_Colab.ipynb	Cuaderno de Google Colab con el código completo

7 Instrucciones para Ejecutar el Código

1. Abrir el archivo Notebook_Colab.ipynb en [Google Colab](#).
2. Ejecutar la celda de código de manera secuencial (*Entorno de ejecución* → *Ejecutar todas*).
3. El cuaderno instala/importa automáticamente las librerías necesarias (**pandas**, **numpy**, **matplotlib**, **seaborn**, **scikit-learn**).
4. Los datos se descargan automáticamente desde los repositorios de GitHub de OWID, por lo que no se requieren archivos locales adicionales.
5. Al finalizar la ejecución, se generará y descargará el archivo `datos_limpios_colombia_1990_2021.xlsx` con la base de datos ya procesada.

8 Referencias

Ritchie, H., Rosado, P., & Roser, M. (2023). *CO₂ and Greenhouse Gas Emissions* [Conjunto de datos]. Our World in Data. <https://github.com/owid/co2-data>

Ritchie, H., Rosado, P., & Roser, M. (2023). *Energy* [Conjunto de datos]. Our World in Data. <https://github.com/owid/energy-data>